UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

FACULTAD DE INGENIERÍA

PROGRAMA ACADÉMICO DE CIENCIAS DE LA COMPUTACIÓN

CURSO: 1ACC0211 – DATA VISUALIZATION

NRC: 18519

TRABAJO 1

INTEGRANTES:

Carbajal Robles, Daniel Ivan (U20221B751)

Manchay Paredes, Lucero Salome (U202216120)

Mayhua Hinostroza, José Antonio (U202218044)

202610

Tabla de Contenido

1. Tema del proyecto.....2

2. Pregunta analítica principal.....3

3. Usuario objetivo.....3

4. Fuente de datos propuesta.....3

5. Hipótesis iniciales.....3

6. Justificación del valor del proyecto.....3

Referencias Bibliográficas.....3

1. Tema del proyecto

Análisis de brechas socioeconómicas y evolución temporal de ingresos y gastos en los hogares peruanos durante el 2024

1.1 Definición del problema y del usuario objetivo

¿Qué problema se quiere analizar?

En el Perú, las cifras macroeconómicas suelen presentar una visión incompleta de la realidad al no reflejar las profundas disparidades que existen entre los hogares según su ubicación y el momento del año. Actualmente, el país enfrenta un entorno donde la inflación persistente y el incremento constante en el coste de vida consumen el poder adquisitivo de las familias de manera progresiva, agudizando su vulnerabilidad económica conforme avanzan los meses (EconoData Soluciones Perú, 2025). Esta presión financiera no se distribuye de forma equitativa: mientras regiones como Ica logran mantener niveles bajos de pobreza, departamentos como Cajamarca o Loreto enfrentan realidades críticas donde la vulnerabilidad alcanza a más del 40% de sus habitantes (INEI, 2025).

Esta desigualdad estructural se traduce en una percepción de precariedad generalizada, donde apenas el 14% de la población siente que sus ingresos son suficientes para cubrir sus necesidades y generar ahorro (Oxfam, 2024). Por lo tanto, el problema que este proyecto busca resolver es la falta de visibilidad articulada sobre cómo estas variables de ingreso y gasto fluctúan mes a mes, una información que es indispensable para identificar los periodos de mayor riesgo económico y diseñar respuestas que no solo sean geográficas, sino también estacionales.

¿Quién usará el dashboard?

- Analistas de planeamiento y focalización del Ministerio de Desarrollo e Inclusión Social (MIDIS).

¿Qué decisión podría apoyarse con el producto final?

- La priorización y asignación eficiente de programas de transferencias monetarias (bonos) y soporte alimentario, identificando los segmentos de hogares con mayor vulnerabilidad a partir del análisis de sus perfiles de brecha ingreso-gasto.

2. Pregunta analítica principal

¿Qué perfiles de hogares peruanos concentran las mayores brechas entre ingreso y gasto durante el 2024, y cómo se distribuyen estos perfiles (clústeres) según el dominio geográfico, el estrato y las características demográficas?

3. Usuario objetivo

Analistas de planeamiento y focalización del Ministerio de Desarrollo e Inclusión Social (MIDIS) que necesitan priorizar programas de asistencia basándose en los patrones de vulnerabilidad y brechas de ingreso-gasto identificadas mediante la segmentación de datos.

4. Fuente de datos propuesta

Nombre: Encuesta Nacional de Hogares (ENAHO) 2024 - Módulo 34: Sumaria (Anual).

Institución: Instituto Nacional de Estadística e Informática (INEI).

Cantidad de datos: 33691 viviendas

Cobertura: Nacional, 24 departamentos y la Provincia Constitucional del Callao, en ámbitos urbano y rural

Licencia y Permisos: Datos Abiertos Gubernamentales (Acceso público, gratuito y de libre uso para fines académicos e investigación).

Enlace oficial: PERÚ Instituto Nacional de Estadística e Informática

Pasos de obtención de datos: Microdatos INEI -> Consulta por Encuestas -> ENAHO Metodología Actualizada -> Condiciones de Vida y Pobreza - ENAHO -> Año 2024 -> Periodo: Anual -> “Módulo 34: Sumarias (Variables Calculadas)”.

Dataset: “Sumaria-2024.csv”

5. Hipótesis iniciales

- Hipótesis 1: El algoritmo de clustering identificará un "perfil de alta vulnerabilidad" predominante en los estratos rurales, el cual se caracteriza por destinar una proporción crítica de su gasto total al rubro de alimentos, dejándolos sin margen frente a shocks inflacionarios.

- Hipótesis 2: La distribución de los perfiles de hogares varía según la estacionalidad; existen meses específicos del año donde la brecha entre ingreso y gasto se acentúa, desplazando temporalmente a hogares de "perfiles estables" hacia "perfiles de riesgo".

6. Justificación del valor del proyecto

El proyecto transforma una de las bases de datos gubernamentales más complejas en una herramienta visual interactiva que permite evidenciar cómo el lugar donde vive una familia determina drásticamente su estabilidad económica (Oxfam, 2024). El desarrollo de este dashboard cumple con el potencial requerido por el curso al permitir un análisis longitudinal (tendencias de gasto e impacto de la inflación mes a mes), segmentación (por niveles de pobreza y tamaño del hogar) y comparación geográfica (urbano vs. rural y dominios geográficos).

- **Adaptación a Tableau:** Elegimos Tableau por dos ventajas prácticas que nos ahorran tiempo y evitan errores. Primero, nos permite transformar los datos de ubicación en un mapa del Perú automáticamente, permitiéndonos visualizar la desigualdad regional sin tener que programar coordenadas desde cero. Segundo, Tableau nos permite configurar el "Factor de Expansión" (FACTOR07) como una regla matemática automática. Esto significa que la herramienta se encarga de ponderar los datos en tiempo real, asegurando que los gráficos no solo muestren una muestra, sino que reflejen con precisión la realidad de toda la población nacional.

- **Producto Analítico Subyacente:** Para responder a la pregunta de negocio sin caer en sesgos de causalidad, el dashboard servirá como la capa final de un modelo analítico exploratorio más profundo. Utilizaremos Python para el cálculo de la variable derivada "brecha ingreso-gasto" y aplicaremos técnicas de reducción de dimensionalidad y segmentación (PCA o k-means) sobre el módulo de sumarias. Esto nos permitirá descubrir "perfiles de hogares" basados en su estructura de consumo, los cuales serán posteriormente consumidos y visualizados en Tableau.

- **Riesgos iniciales de calidad y cobertura:** Antes de llevar los datos a Tableau, usaremos Python para solucionar dos problemas típicos de las encuestas del Estado. Primero, filtraremos los "outliers" (hogares que declaran ingresos extremadamente altos o irreales); si no los quitamos, el "ingreso promedio" en nuestros gráficos será engañoso. Segundo, traduciremos los códigos del INEI. Como la base de datos original usa números en lugar de texto (por ejemplo, usa el "15" en lugar de decir "Lima"), programaremos un script para convertir todos esos números a sus nombres reales, asegurando que Tableau pueda leer los mapas y las categorías sin confundirse.

Enlace del dataset:
https://drive.google.com/file/d/1fNnNoEplQlQ9-jlwHUVkHHnpK8R47t-_/view?usp=sharing

El módulo Sumaria consolida a nivel de hogar los principales indicadores económicos del hogar, calculados con la metodología oficial del INEI, lo que garantiza comparabilidad con los reportes institucionales. Asimismo, estas variables cubren los tres ejes del análisis propuesto: la evolución mensual de los indicadores, la diferenciación por perfil socioeconómico y la comparación entre territorios.

7. Diccionario de Datos (18 Variables Seleccionadas)

Variable	Tipo	Descripción	Eje Analítico	Justificación Técnica	Tratamiento en Limpieza
MES	String	Mes de ejecución de la encuesta	Temporal	Permite construir la serie	Se aseguró formato String de 2

				temporal mensual para analizar la estacionalidad de la brecha ingreso-gasto.	dígitos (padding con ceros a la izquierda).
UBIGEO	String	Código de ubicación geográfica	Geográfico	Permite georreferenciar los hogares en Tableau para construir mapas departamentales.	Se aseguró formato String de 6 dígitos (padding con ceros a la izquierda). Vital para mapas en Tableau.
DOMINIO	Categoría (String)	Dominio geográfico (Costa Norte, Sierra, Selva, Lima Metropolitana, etc.)	Segmentación geográfica	Permite comparar perfiles de hogares entre las grandes regiones naturales del país.	Se tradujo de Integer (1-8) a texto (Costa Norte, Sierra Centro, Lima Metropolitana, etc.).
ESTRATO	Categoría (String)	Estrato geográfico según tamaño de población	Segmentación geográfica	Diferencia el ámbito urbano del rural para identificar concentración de perfiles vulnerables.	Se tradujo de Integer (1-8) a texto descriptivo.
POBREZA	Categoría (String)	Condición de pobreza monetaria del hogar	Clasificación y filtro	Permite validar si los perfiles del clustering coinciden con la clasificación oficial del INEI.	Se tradujo de Integer (1-3) a texto (Pobre Extremo, Pobre No Extremo, No Pobre).
POBREZAV	Categoría (String)	Condición de pobreza y vulnerabilida	Clasificación y filtro	Amplía la clasificación incluyendo	Se tradujo de Integer (1-4) a texto.

		d del hogar		hogares vulnerables no pobres, enriqueciendo la segmentación.	
INGHOG2D	Float	Ingreso neto total del hogar	Métrica base	Ingreso real disponible del hogar, uno de los dos ejes para calcular la brecha ingreso-gasto.	Conservado como número. Se filtraron valores atípicos (outliers) mediante IQR.
GASHOG2D	Float	Gasto total bruto del hogar	Métrica base	Junto con INGHOG2D permite construir la brecha ingreso-gasto y determinar qué hogares logran ahorrar.	Conservado como número.
MIEPERHO	Integer	Total de miembros del hogar	Normalización	Permite calcular ingreso y gasto per cápita, haciendo comparables hogares de distinto tamaño.	Conservado como número.
GRU11HD	Float	Grupo 1: Alimentos - gasto monetario	Dimensión para PCA/clustering	Representa la proporción del gasto destinada a alimentación dentro de la estructura de consumo del hogar.	Conservado como número.

GRU21HD	Float	Grupo 2: Vestido y calzado - gasto monetario	Dimensión para PCA/clustering	Captura el gasto en necesidades básicas secundarias para distinguir perfiles de consumo.	Conservado como número.
GRU31HD	Float	Grupo 3: Vivienda, combustible y electricidad- gasto monetario	Dimensión para PCA/clustering	Refleja el peso de los gastos fijos del hogar en servicios básicos.	Conservado como número.
GRU41HD	Float	Grupo 4: Muebles, enseres y mantenimiento - gasto monetario	Dimensión para PCA/clustering	Indica la capacidad del hogar para invertir más allá de las necesidades inmediatas.	Conservado como número.
GRU51HD	Float	Grupo 5: Salud y servicios médicos - gasto monetario	Dimensión para PCA/clustering	Permite detectar perfiles con acceso limitado o nulo a gasto en salud.	Conservado como número.
GRU61HD	Float	Grupo 6: Transportes y comunicaciones - gasto monetario	Dimensión para PCA/clustering	Refleja el nivel de movilidad e inserción económica del hogar.	Conservado como número.
GRU71HD	Float	Grupo 7: Esparcimiento, cultura y enseñanza - gasto monetario	Dimensión para PCA/clustering	Captura inversión en capital humano y calidad de vida del hogar.	Conservado como número.
GRU81HD	Float	Grupo 8:	Dimensión	Completa el	Conservado

		Otros bienes y servicios - gasto monetario	para PCA/clustering	vector de 8 variables numéricas requerido para el componente avanzado PCA/t-SNE.	como número.
FACTOR07	Float	Factor de expansión anual	Ponderación estadística	Garantiza que los cálculos representen a la población nacional y no solo a la muestra encuestada.	Conservado como número para su uso como ponderador en Tableau.

8. Bitácora de Transformación

1. **Detección de Codificación:** Se leyó el dataset original ("Sumaria-2024.csv") usando codificación "latin1" para evitar la corrupción de caracteres especiales en las cabeceras.

2. **Reducción de Dimensionalidad:** Se eliminaron las columnas innecesarias del módulo original, reduciendo el dataset estrictamente a las 18 variables arriba listadas.

3. **Conversión de Identificadores (UBIGEO y MES):** La columna "UBIGEO" se convirtió a String forzando un padding con ceros a la izquierda mediante el uso de la función "zfill(6)". Esto soluciona que Tableau no lea los UBIGEos que inician con "0" (como Amazonas = 010101) como números enteros. Igual tratamiento se aplicó para "MES" con "zfill(2)".

4. **Traducción de variables (DOMINIO, ESTRATO, POBREZA y POBREZAV):** Se construyeron diccionarios en memoria y se utilizó la función ".map()" de Pandas para traducir los códigos numéricos a texto descriptivo.

5. **Manejo de Outliers (2,037 filas eliminadas):** Se detectaron valores atípicos en la variable de ingresos "INGHOG2D" utilizando el método del Rango Intercuartílico (IQR). Por este motivo, se eliminaron exactamente 2,037 filas del dataset original (reduciendo de 33,691 a 31,654 registros). Esto fue crucial para no distorsionar los promedios en el dashboard.

6. **Exportación y corrección de Encoding (ESTRATO):** Se exportó el dataset limpio bajo el nombre "Sumaria-2024_limpio.csv" forzando el formato de codificación "utf-8-sig" (UTF-8 con BOM). Esta corrección del encoding solucionó el problema en la variable ESTRATO, donde caracteres como "Área" y "más" se mostraban corruptos

en Tableau o Excel. Además, se forzó el uso de comillas dobles para variables tipo texto.

Link del repositorio: https://github.com/YuhiTTo/GRUPO5-DATAVISUALIZATION.git

Referencias Bibliográficas

- EconoData Soluciones Perú. (2025). Ensayo: Inflación y coste de vida 2025. Recuperado de https://econodatasolucionesperu.com/wp-content/uploads/2025/04/Ensayo-Inflacion-y-coste-de-vida-2025-N1.pdf
- Instituto Nacional de Estadística e Informática (INEI). (2025). Pobreza monetaria afectó al 27,6% de la población del país en el año 2024. Gobierno del Perú. https://www.gob.pe/institucion/inei/noticias/1164173-pobreza-monetaria-afecto-al-27-6-de-la-poblacion-del-pais-en-el-ano-2024
- Oxfam en Perú. (2024). ENADES 2024: Encuesta Nacional de Percepción de Desigualdades. https://peru.oxfam.org/ENADES-2024
- Instituto Nacional de Estadística e Informática. (s. f.). *Microdatos: Sistema de Consulta de Microdatos*. Recuperado de https://proyectos.inei.gob.pe/microdatos/

Mini Ficha del Proyecto

Campo	Contenido
Título	Análisis de brechas socioeconómicas y evolución temporal de ingresos y gastos en los hogares peruanos durante el 2024
Pregunta analítica	¿Qué perfiles de hogares peruanos concentran las mayores brechas entre ingreso y gasto durante el 2024, y cómo se distribuyen estos perfiles (clústeres) según el dominio geográfico, el estrato y las características demográficas?

Usuario objetivo	Analistas de planeamiento y focalización del Ministerio de Desarrollo e Inclusión Social (MIDIS) que necesitan priorizar programas de asistencia basándose en los patrones de vulnerabilidad y brechas de ingreso-gasto identificadas mediante la segmentación de datos.
Fuente de datos	ENAHO 2024 - Módulo 34: Sumaria (Variables Calculadas), INEI
Registros	33,691 viviendas
Periodo	Enero - Diciembre 2024
Herramientas	Python (limpieza, creación de métricas y modelo de clustering/PCA) + Tableau (dashboard exploratorio final)
Hipótesis 1	El algoritmo de clustering identificará un "perfil de alta vulnerabilidad" predominante en los estratos rurales, el cual se caracteriza por destinar una proporción crítica de su gasto total al rubro de alimentos, dejándolos sin margen frente a shocks inflacionarios.
Hipótesis 2	La distribución de los perfiles de hogares varía según la estacionalidad; existen meses específicos del año donde la brecha entre ingreso y gasto se acentúa, desplazando temporalmente a hogares de "perfiles estables" hacia "perfiles de riesgo".
Riesgos identificados	Presencia de outliers en variables de ingreso y gasto, y variables categóricas codificadas numéricamente que requieren traducción previa al análisis.
Producto final	Dashboard interactivo en Tableau que actúa como capa visual de un modelo de clustering (generado en Python), permitiendo explorar la distribución de perfiles de hogares según su brecha económica, temporalidad y geografía.