



UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

FACULTAD DE INGENIERÍA

PROGRAMA ACADÉMICO DE CIENCIAS DE LA COMPUTACIÓN

CURSO: 1ACC0211 – DATA VISUALIZATION

NRC: 18519

TRABAJO 4

INTEGRANTES:

Carbajal Robles, Daniel Ivan (U20221B751)

Manchay Paredes, Lucero Salome (U202216120)

Mayhua Hinostroza, José Antonio (U202218044)

Tabla de Contenido

1. Tema del proyecto.....	3
2. Pregunta analítica principal.....	3
3. Usuario objetivo.....	4
4. Fuente de datos propuesta.....	4
5. Hipótesis iniciales.....	4
6. Justificación del valor del proyecto.....	4
7. Diccionario de Datos (18 Variables Seleccionadas).....	5
8. Bitácora de Transformación.....	9
Referencias Bibliográficas.....	10
Mini Ficha del Proyecto.....	10

1. Tema del proyecto

Análisis de brechas socioeconómicas y evolución temporal de ingresos y gastos en los hogares peruanos durante el 2024

1.1 Definición del problema y del usuario objetivo

¿Qué problema se quiere analizar?

En el Perú, las cifras macroeconómicas suelen presentar una visión incompleta de la realidad al no reflejar las profundas disparidades que existen entre los hogares según su ubicación y el momento del año. Actualmente, el país enfrenta un entorno donde la inflación persistente y el incremento constante en el coste de vida consumen el poder adquisitivo de las familias de manera progresiva, agudizando su vulnerabilidad económica conforme avanzan los meses (EconoData Soluciones Perú, 2025). Esta presión financiera no se distribuye de forma equitativa: mientras regiones como Ica logran mantener niveles bajos de pobreza, departamentos como Cajamarca o Loreto enfrentan realidades críticas donde la vulnerabilidad alcanza a más del 40% de sus habitantes (INEI, 2025).

Esta desigualdad estructural se traduce en una percepción de precariedad generalizada, donde apenas el 14% de la población siente que sus ingresos son suficientes para cubrir sus necesidades y generar ahorro (Oxfam, 2024). Por lo tanto, el problema que este proyecto busca resolver es la falta de visibilidad articulada sobre cómo estas variables de ingreso y gasto fluctúan mes a mes, una información que es indispensable para identificar los periodos de mayor riesgo económico y diseñar respuestas que no solo sean geográficas, sino también estacionales.

¿Quién usará el dashboard?

- Analistas de planeamiento y focalización del Ministerio de Desarrollo e Inclusión Social (MIDIS).

¿Qué decisión podría apoyarse con el producto final?

- La priorización y asignación eficiente de programas de transferencias monetarias (bonos) y soporte alimentario, identificando los segmentos de hogares con mayor vulnerabilidad a partir del análisis de sus perfiles de brecha ingreso-gasto.

2. Pregunta analítica principal

¿Qué perfiles de hogares peruanos concentran las mayores brechas entre ingreso y gasto durante el 2024, y cómo se distribuyen estos perfiles (clústeres) según el dominio geográfico, el estrato y las características demográficas?

3. Usuario objetivo

Analistas de planeamiento y focalización del Ministerio de Desarrollo e Inclusión Social (MIDIS) que necesitan priorizar programas de asistencia basándose en los patrones de vulnerabilidad y brechas de ingreso-gasto identificadas mediante la segmentación de datos.

4. Fuente de datos propuesta

Nombre: Encuesta Nacional de Hogares (ENAH) 2024 - Módulo 34: Sumaria (Anual).

Institución: Instituto Nacional de Estadística e Informática (INEI).

Cantidad de datos: 33691 viviendas

Cobertura: Nacional, 24 departamentos y la Provincia Constitucional del Callao, en ámbitos urbano y rural

Licencia y Permisos: Datos Abiertos Gubernamentales (Acceso público, gratuito y de libre uso para fines académicos e investigación).

Enlace oficial: [PERÚ Instituto Nacional de Estadística e Informática](#)

Pasos de obtención de datos: Microdatos INEI -> Consulta por Encuestas -> ENAH Metodología Actualizada -> Condiciones de Vida y Pobreza - ENAH -> Año 2024 -> Periodo: Anual -> "Módulo 34: Sumarias (Variables Calculadas)".

Dataset: "Sumaria-2024.csv"

5. Hipótesis iniciales

- Hipótesis 1: El algoritmo de clustering identificará un "perfil de alta vulnerabilidad" predominante en los estratos rurales, el cual se caracteriza por destinar una proporción crítica de su gasto total al rubro de alimentos, dejándolos sin margen frente a shocks inflacionarios.
- Hipótesis 2: La distribución de los perfiles de hogares varía según la estacionalidad; existen meses específicos del año donde la brecha entre ingreso y gasto se acentúa, desplazando temporalmente a hogares de "perfiles estables" hacia "perfiles de riesgo".

6. Justificación del valor del proyecto

El proyecto transforma una de las bases de datos gubernamentales más complejas en una herramienta visual interactiva que permite evidenciar cómo el lugar donde vive una familia determina drásticamente su estabilidad económica (Oxfam, 2024). El desarrollo de este dashboard cumple con el potencial requerido por el curso al permitir un análisis longitudinal (tendencias de gasto e impacto de la inflación mes a mes), segmentación (por niveles de pobreza y tamaño del hogar) y comparación geográfica (urbano vs. rural y dominios geográficos).

- **Adaptación a Tableau:** Elegimos Tableau por dos ventajas prácticas que nos ahorran tiempo y evitan errores. Primero, nos permite transformar los datos de ubicación en un mapa del Perú automáticamente, permitiéndonos visualizar la desigualdad regional sin tener que programar coordenadas desde cero. Segundo, Tableau nos permite configurar el "Factor de Expansión" (FACTOR07) como una regla matemática automática. Esto significa que la herramienta se encarga de ponderar los datos en tiempo real, asegurando que los gráficos no solo muestren una muestra, sino que reflejen con precisión la realidad de toda la población nacional.
- **Producto Analítico Subyacente:** Para responder a la pregunta de negocio sin caer en sesgos de causalidad, el dashboard servirá como la capa final de un modelo analítico exploratorio más profundo. Utilizaremos Python para el cálculo de la variable derivada "brecha ingreso-gasto" y aplicaremos técnicas de reducción de dimensionalidad y segmentación (PCA o k-means) sobre el módulo de sumarias. Esto nos permitirá descubrir "perfiles de hogares" basados en su estructura de consumo, los cuales serán posteriormente consumidos y visualizados en Tableau.
- **Riesgos iniciales de calidad y cobertura:** Antes de llevar los datos a Tableau, usaremos Python para solucionar dos problemas típicos de las encuestas del Estado. Primero, filtraremos los "outliers" (hogares que declaran ingresos extremadamente altos o irreales); si no los quitamos, el "ingreso promedio" en nuestros gráficos será engañoso. Segundo, traduciremos los códigos del INEI. Como la base de datos original usa números en lugar de texto (por ejemplo, usa el "15" en lugar de decir "Lima"), programaremos un script para convertir todos esos números a sus nombres reales, asegurando que Tableau pueda leer los mapas y las categorías sin confundirse.

Enlace del dataset:

<https://drive.google.com/file/d/1fNnNoEplQIQ9-jlwHUVkHHnpK8R47t-/view?usp=sharing>

El módulo Sumaria consolida a nivel de hogar los principales indicadores económicos del hogar, calculados con la metodología oficial del INEI, lo que garantiza comparabilidad con los reportes institucionales. Asimismo, estas variables cubren los tres ejes del análisis propuesto: la evolución mensual de los indicadores, la diferenciación por perfil socioeconómico y la comparación entre territorios.

7. Diccionario de Datos (Variables Base y Métricas Derivadas)

Variable	Tipo	Descripción	Eje Analítico	Justificación Técnica	Tratamiento en Limpieza
MES	String	Mes de ejecución de la encuesta	Temporal	Permite construir la serie	Se aseguró formato String de 2

				temporal mensual para analizar la estacionalidad de la brecha ingreso-gasto.	dígitos (padding con ceros a la izquierda).
UBIGEO	String	Código de ubicación geográfica	Geográfico	Permite georreferenciar los hogares en Tableau para construir mapas departamentales.	Se aseguró formato String de 6 dígitos (padding con ceros a la izquierda). Vital para mapas en Tableau.
DOMINIO	Categoría (String)	Dominio geográfico (Costa Norte, Sierra, Selva, Lima Metropolitana, etc.)	Segmentación geográfica	Permite comparar perfiles de hogares entre las grandes regiones naturales del país.	Se tradujo de Integer (1-8) a texto (Costa Norte, Sierra Centro, Lima Metropolitana, etc.).
ESTRATO	Categoría (String)	Estrato geográfico según tamaño de población	Segmentación geográfica	Diferencia el ámbito urbano del rural para identificar concentración de perfiles vulnerables.	Se tradujo de Integer (1-8) a texto descriptivo.
POBREZA	Categoría (String)	Condición de pobreza monetaria del hogar	Clasificación y filtro	Permite validar si los perfiles del clustering coinciden con la clasificación oficial del INEI.	Se tradujo de Integer (1-3) a texto (Pobre Extremo, Pobre No Extremo, No Pobre).
POBREZAV	Categoría (String)	Condición de pobreza y vulnerabilidad	Clasificación y filtro	Amplía la clasificación incluyendo	Se tradujo de Integer (1-4) a texto.

		ad del hogar		hogares vulnerables no pobres, enriqueciendo la segmentación.	
INGHOG2D	Float	Ingreso neto total del hogar	Métrica base	Ingreso real disponible del hogar, uno de los dos ejes para calcular la brecha ingreso-gasto.	Conservado como número. Se filtraron valores atípicos (outliers) mediante IQR.
GASHOG2D	Float	Gasto total bruto del hogar	Métrica base	Junto con INGHOG2D permite construir la brecha ingreso-gasto y determinar qué hogares logran ahorrar.	Conservado como número.
MIEPERHO	Integer	Total de miembros del hogar	Normalización	Permite calcular ingreso y gasto per cápita, haciendo comparables hogares de distinto tamaño.	Conservado como número.
GRU11HD	Float	Grupo 1: Alimentos - gasto monetario	Dimensión para PCA/clustering	Representa la proporción del gasto destinada a alimentación dentro de la estructura de consumo del hogar.	Conservado como número.

GRU21HD	Float	Grupo 2: Vestido y calzado - gasto monetario	Dimensión para PCA/clustering	Captura el gasto en necesidades básicas secundarias para distinguir perfiles de consumo.	Conservado como número.
GRU31HD	Float	Grupo 3: Vivienda, combustible y electricidad- gasto monetario	Dimensión para PCA/clustering	Refleja el peso de los gastos fijos del hogar en servicios básicos.	Conservado como número.
GRU41HD	Float	Grupo 4: Muebles, enseres y mantenimiento - gasto monetario	Dimensión para PCA/clustering	Indica la capacidad del hogar para invertir más allá de las necesidades inmediatas.	Conservado como número.
GRU51HD	Float	Grupo 5: Salud y servicios médicos - gasto monetario	Dimensión para PCA/clustering	Permite detectar perfiles con acceso limitado o nulo a gasto en salud.	Conservado como número.
GRU61HD	Float	Grupo 6: Transportes y comunicaciones - gasto monetario	Dimensión para PCA/clustering	Refleja el nivel de movilidad e inserción económica del hogar.	Conservado como número.
GRU71HD	Float	Grupo 7: Esparcimiento, cultura y enseñanza - gasto monetario	Dimensión para PCA/clustering	Captura inversión en capital humano y calidad de vida del hogar.	Conservado como número.
GRU81HD	Float	Grupo 8:	Dimensión	Completa el	Conservado

		Otros bienes y servicios - gasto monetario	para PCA/clustering	vector de 8 variables numéricas requerido para el componente avanzado PCA/t-SNE.	como número.
FACTOR07	Float	Factor de expansión anual	Ponderación estadística	Garantiza que los cálculos representen a la población nacional y no solo a la muestra encuestada.	Conservado como número para su uso como ponderador en Tableau.
BRECHA_HOG	Float	Brecha absoluta del hogar	Métrica derivada	Diferencia directa entre INGHOG2D y GASHOG2D.	Calculada como INGHOG2D - GASHOG2D.
EN_DEFICIT	Integer	Indicador de déficit (0 o 1)	Clasificación	Flag analítico para identificar fácilmente hogares que gastan más de lo que ingresan.	Calculada como 1 si BRECHA_HOG < 0, sino 0.
ING_PERCAPITA	Float	Ingreso por miembro	Normalización	Permite comparar hogares de distinto tamaño.	Calculada como INGHOG2D / MIEPERHO.
GAS_PERCAPITA	Float	Gasto por miembro	Normalización	Permite comparar hogares de distinto tamaño.	Calculada como GASHOG2D / MIEPERHO.
BRECHA_PERCAPITA	Float	Brecha por miembro	Normalización	Métrica comparable	Calculada como

				de capacidad de ahorro/déficit entre hogares.	BRECHA_HOG / MIEPERHO.
MES_NUM	Integer	Mes numérico	Tiempo	MES como string puede ordenarse lexicográficamente en lugar de cronológicamente en Tableau. La versión entera garantiza orden correcto en ejes temporales.	Conversión de MES a numérico.
DEPARTAMENTO	String	Nombre del departamento	Comparación geográfica	UBIGEO de 6 dígitos no tiene semántica legible. Se extrae el código de departamento (primeros 2 dígitos) y se mapea al nombre oficial INEI para comparaciones y mapas departamentales.	Derivada de los 2 primeros dígitos del UBIGEO.
LOG_INGHOG2D / LOG_GASH	Float	Logaritmo de Ingresos,	Distribución	Ingresos y gastos tienen distribución	Aplicación de logaritmo log1p.

OG2D / LOG_BRECHA_PERCAP		Gastos y Brecha		fuertemente sesgada a la derecha. La transformación logarítmica permite leer histogramas y box plots sin que la cola aplaste la varianza central.	
GRU{i}1HD_PCT	Float	% de participación de los 8 rubros de gasto	Relación / composición	Los montos brutos de cada rubro son incomparables entre hogares de distinto nivel de ingreso. La proporción sobre la canasta monetaria total normaliza la comparación.	Calculada dividiendo el gasto de cada rubro (ej. 'GRU11HD') entre la suma estricta de los 8 rubros ('GRU11HD' a 'GRU81HD').
TASA_AHORRO	Float	Margen de brecha relativa	Métrica derivada (Clustering)	permite medir qué porcentaje de su ingreso total logra ahorrar el hogar, normalizando la brecha absoluta.	Calculada como $\frac{(\text{INGHOG2D} - \text{GASHOG2D})}{\text{INGHOG2D}}$. Si el ingreso es 0, la tasa es 0.

ID_SEGMENTS	Integer	Llave foránea del perfil financiero	Segmentación (Clustering)	Identifica si el hogar es Ahorrador Sólido, Equilibrio, Déficit Leve o Déficit Crítico.	Asignada mediante condicionales sobre la 'TASA_AHORRO'.
-------------	---------	-------------------------------------	---------------------------	---	---

8. Bitácora de Transformación

8.1 Detección de Codificación: Se leyó el dataset original ("Sumaria-2024.csv") usando codificación "latin1" para evitar la corrupción de caracteres especiales en las cabeceras.

8.2 Reducción de Dimensionalidad: Se eliminaron las columnas innecesarias del módulo original, reduciendo el dataset estrictamente a las 18 variables arriba listadas.

8.3 Conversión de Identificadores (UBIGEO y MES): La columna "UBIGEO" se convirtió a String forzando un padding con ceros a la izquierda mediante el uso de la función "zfill(6)". Esto soluciona que Tableau no lea los UBIGEos que inician con "0" (como Amazonas = 010101) como números enteros. Igual tratamiento se aplicó para "MES" con "zfill(2)".

8.4 Traducción de variables (DOMINIO, ESTRATO, POBREZA y POBREZAV): Se construyeron diccionarios en memoria y se utilizó la función ".map()" de Pandas para traducir los códigos numéricos a texto descriptivo.

8.5 Manejo de Outliers: Se detectaron valores atípicos en las variables de ingresos y gastos utilizando el método del Rango Inter cuartílico (IQR). A diferencia de entregas previas, no se eliminaron filas. En su lugar, se imputaron los valores extremos con la mediana del grupo de pobreza al que pertenece el hogar. Esto permite conservar los 33,691 registros originales sin distorsionar la realidad de la brecha económica del país. Además, se crearon versiones logarítmicas de estas variables para su posterior uso en modelos.

8.6 Exportación y corrección de Encoding (ESTRATO): Se exportó el dataset limpio bajo el nombre "Sumaria-2024_limpio.csv" forzando el formato de codificación "utf-8-sig" (UTF-8 con BOM). Esta corrección del encoding solucionó el problema en la variable ESTRATO, donde caracteres como "Área" y "más" se mostraban corruptos en Tableau o Excel. Además, se forzó el uso de comillas dobles para variables tipo texto.

8.7 Modelado de Datos: Se estructuró la data limpia en un Esquema Estrella creando una Tabla de Hechos y Dimensiones (Geografía, Tiempo, Pobreza) tras corroborar

mediante pruebas de estrés (Benchmarking) un ahorro de RAM del 33% frente a la Tabla Plana. En esta fase de importación/exportación se re-aplicó el “.astype(str).str.zfill(6)” al “UBIGEO” para evitar que la lectura de Pandas lo interpretará como entero por defecto y truncara los ceros a la izquierda geográficos.

8.8 Cálculos Analíticos y Segmentación: Se añadió la métrica derivada “TASA_AHORRO” a la tabla de hechos. Con esta métrica, se crearon 4 clústeres financieros plasmados en la nueva tabla “dim_segmento”. Además, se recalculó la matemática de las participaciones porcentuales de gasto (“_PCT”) para que el denominador sea la suma estricta de la canasta y no el gasto bruto (“GASHOG2D”), garantizando que la suma por hogar sea exactamente “1.0” (100%). Se validó que no existan llaves foráneas nulas y que los tipos de datos sean compatibles nativamente con Tableau.

9. Preprocesamiento para el Modelado

Para esta entrega, el objetivo fue preparar la arquitectura de datos que será consumida directamente por Tableau. Se partió del archivo Sumaria-2024_limpio.csv (33,691 registros y 26 variables, incluyendo métricas derivadas).

Pasos ejecutados de forma reproducible:

9.1. Generación de Claves Primarias: Dado que en la reducción de dimensionalidad se eliminaron las llaves originales del INEI (CONGLOME, VIVIENDA, HOGAR), se generó una clave primaria secuencial subrogada ID_HOGAR (del 1 al 33,691) para garantizar que cada registro sea único en la tabla principal y optimizar la velocidad computacional en Tableau.

9.2. Generación de Claves para Dimensiones: Se crearon claves foráneas como “ID_POBREZA” (secuencial) e “ID_GEOGRAFIA” (secuencial) cruzando combinaciones únicas de atributos categóricos, garantizando integridad referencial.

9.3. Formateo Estructural de Identificadores: Las herramientas como Tableau dependen de tipos de datos estrictos. Se forzó el tipado String para el “UBIGEO” aplicando la función “zfill(6)” durante la carga. Esto soluciona un error crítico de ingesta donde códigos geográficos como Amazonas (“010101”) perdían su cero a la izquierda.

9.4. Validación de Integridad: Se validó de forma automatizada (mediante asserts en Python) que hacer un “inner join” entre la Tabla de Hechos y las Tablas de Dimensión diera como resultado exactamente las mismas 33,691 filas iniciales, asegurando cero pérdida de datos.

10. Opciones de Modelo Consideradas

Como las herramientas de visualización de datos como Tableau requieren estructuras altamente eficientes para procesar millones de registros, se compararon dos modelos clásicos de Data Warehousing:

Opción 1: Modelo de Tabla Plana (Flat Table) - Modelo Base

Es una única tabla desnormalizada ("sábana de datos") donde toda la información se concentra en cada registro.

- **Funcionamiento:** Similar a un archivo Excel tradicional. Si hay 10,000 hogares en “Lima Metropolitana”, el texto se repite 10,000 veces.
- **Ventaja:** Fácil lectura humana directa sin necesidad de realizar cruces de tablas.
- **Desventaja (Por qué se descartó):** Altísima redundancia. Demostramos empíricamente que proyectar datos históricos en este formato hace que el archivo se vuelva insosteniblemente pesado en memoria.

Opción 2: Esquema Estrella (Star Schema) - Modelo Propuesto

Un modelo normalizado donde el dataset se divide en una tabla central rodeada de dimensiones lógicas (diccionarios):

- **Tabla de Hechos (fact_hogares):** Guarda estrictamente números puros (Gastos, Ingresos, Brechas, IDs) y las llaves foráneas. Cero texto descriptivo.
- **Las Dimensiones:** Son diccionarios para Geografía (dim_geografía), Tiempo (dim_tiempo) y Pobreza (dim_pobreza).
- **Ventaja:** Elimina la redundancia ahorrando memoria masivamente (33%). Además, permite que Tableau renderice visualizaciones a máxima velocidad porque solo requiere un salto directo (1 Join) desde los Hechos a cualquier Dimensión.

Opción 3: Esquema Copo de Nieve (Snowflake Schema)

Es una variación de la Estrella llevada a una normalización extrema (3NF), donde las ramas se rompen en pedazos más pequeños:

- **Funcionamiento:** La dimensión geográfica se disgrega. “dim_geografia_snow” elimina el texto del departamento y lo vincula a una nueva tabla aislada “dim_departamento” mediante un “ID_DEP”.
- **Desventaja (Por qué se descartó):** Aunque logra una compresión fraccionalmente mejor, obliga al motor de Tableau a realizar múltiples saltos en cascada (Joins encadenados: Hechos -> Geografía -> Departamento). Este costo topológico ralentiza los cruces sin justificar el minúsculo ahorro de RAM.

11. Pruebas de Benchmarking Analítico

Para no depender de preferencias técnicas, se ejecutó un script en Python que calculó matemáticamente el peso en Memoria RAM (Sparsity) y el Costo Topológico de cada arquitectura sobre nuestros 33,691 registros:

Métrica Evaluada (Evidencia)	Alternativa Base (Tabla Plana)	Opción 1 (Esquema Estrella)	Opción 2 (Copo de Nieve)	Veredicto Empírico
Memoria RAM (MB)	12.15 MB	8.15 MB (-32.88%)	8.14 MB (-32.98%)	Ambos esquemas relacionales reducen la redundancia categórica en casi un 33%. El Copo de Nieve ahorra marginalmente (0.01 MB).
Proyección a 5 Años (MB)	60.73 MB	40.03 MB (-34.08%)	40.01 MB (-34.11%)	Al simular 5 años históricos, la brecha absoluta de ahorro sube a más de 20 MB, ya que las dimensiones estrella permanecen estáticas.
Costo Topológico (Saltos)	Bajo (0 Joins)	Moderado (1 Join directo)	Alto (2 Joins en cascada)	El Copo de Nieve exige un Join adicional (Geografía -> Departamento), degradando la velocidad de lectura en Tableau.

12. Definición del Modelo Seleccionado

Decisión: El modelo seleccionado para alimentar el Dashboard de la Entrega 4 es la Opción 1: Esquema Estrella (Star Schema).

Justificación Basada en Evidencia:

A diferencia del enfoque tradicional, hemos basado la decisión en mediciones exactas extraídas de Python (benchmarking_resultados.csv):

- **Prueba de Escalabilidad:** La Tabla Plana se descartó porque demostramos empíricamente su fragilidad histórica. Al simular la inyección de 5 encuestas anuales (2020-2024), la redundancia de texto (ej. repetir "Lima Metropolitana" miles de veces) provoca que la Tabla Plana colapse consumiendo 60.73 MB de memoria RAM. Por el contrario, el Esquema Estrella mantiene estáticas sus dimensiones geográficas y de pobreza, limitando el consumo a 40.03 MB (un ahorro proyectado del 34.08%).
- **Costo Topológico:** El Copo de Nieve logró comprimir la memoria en proporciones casi idénticas a la Estrella (solo ganamos 0.02 MB extra). Sin embargo, nos penaliza

con un salto de Join adicional en cascada. Ejemplo práctico: Si en Tableau el usuario quiere filtrar los gastos por "Amazonas", en el Esquema Estrella el sistema viaja directo de la Tabla de Hechos a la de Geografía (1 salto). En el Copo de Nieve, tiene que viajar de los Hechos a la Geografía, y de ahí al Departamento (2 saltos). Esta cadena de cruces haría que los mapas departamentales en Tableau se rendericen mucho más lento.

Por lo tanto, la evidencia indica que el Esquema Estrella es el punto de equilibrio óptimo entre máxima compresión de memoria para datos históricos (ahorro del 34.08% a 5 años) y velocidad de consulta directa (1 Join).

13. Estructura analítica o relacional para Tableau

Se mantiene la arquitectura en Esquema Estrella centralizada. Para cumplir con las mejores prácticas y no duplicar métricas sin control en la tabla de hechos, se diseñó e integró una nueva dimensión analítica llamada `dim_segmento`.

- **Validación:** Se ejecutaron pruebas de integridad referencial asegurando que la conexión entre `fact_hogares` y sus dimensiones (incluyendo la nueva llave foránea `ID_SEGMENTO`) presenta ausencia absoluta de valores Nulos y tipado Entero. Esto asegura una conexión nativa y fluida en Tableau sin reprocesamiento manual.

14. Métricas derivadas para visualización

Para responder de forma precisa a nuestra pregunta analítica sobre brechas económicas, se generó una métrica derivada transversal:

Tasa de Ahorro (Margen de Brecha Relativa):

- **Cálculo:** $(INGHOG2D - GASHOG2D) / INGHOG2D$.
- **Impacto en la interpretación:** A diferencia de la brecha absoluta, esta métrica relativa nos permite comparar equitativamente la capacidad financiera de hogares ricos y pobres. Un déficit de 500 soles no significa lo mismo para quien gana 1,000 que para quien gana 10,000.
- **Corrección Analítica:** Se recalcularon las participaciones proporcionales de gasto (`_PCT`) tomando como base la suma estricta de la canasta de 8 rubros, en lugar del Gasto Bruto (el cual incluía componentes no monetarios). Esto garantiza que, al apilar barras al 100% en Tableau, las sumas sean matemáticamente exactas.

15. Segmentación

Con base en la `TASA_AHORRO`, se creó un clúster financiero para agrupar a los hogares en 4 perfiles de vulnerabilidad, independientemente de la clasificación oficial de pobreza. Casi 1 de cada 4 hogares peruanos (23.8%) se ubica en el déficit más extremo:

- **Ahorrador Sólido (ID_SEGMENTO = 1):** Tasa $\geq 15\%$. Alta holgura económica mensual. (Paleta: Verde)
- **Equilibrio / Supervivencia (ID_SEGMENTO = 2):** $0\% \leq \text{Tasa} < 15\%$. Nula o escasa capacidad de ahorro; vulnerables a shocks. (Paleta: Naranja)
- **Déficit Leve (ID_SEGMENTO = 3):** $-15\% \leq \text{Tasa} < 0\%$. Gastan por encima de sus ingresos, con deuda manejable. (Paleta: Rojo)
- **Déficit Crítico (ID_SEGMENTO = 4):** Tasa $< -15\%$. Hogares en estrés financiero severo. (Paleta: Marrón)

16. Parámetros o lógica analítica

Para el futuro Dashboard, se diseñó la lógica analítica de un "Simulador de Inflación Alimentaria".

- **Diseño del Parámetro:** [Inflación Alimentos] (Rango: 0 a 0.50).
- **Cálculo Afectado:** $\text{Gasto_Simulado} = \text{GASHOG2D} + (\text{GRU11HD} * [\text{Inflación Alimentos}])$.
- **Interpretación:** Este parámetro de interacción permitirá al usuario simular un shock inflacionario en tiempo real, observando cuántas familias caerían del segmento "Equilibrio" al "Déficit Crítico" si el costo de los alimentos sube, agregando gran valor al análisis exploratorio.

17. Fuentes finales o semidefinitivas para Tableau

El procesamiento concluyó con la exportación del modelo optimizado a la carpeta Data/modelo/esquema_estrella/.

- **fact_hogares.csv:** Actualizado con las nuevas métricas (Tasa de Ahorro y ID_SEGMENTO).
- **dim_segmento.csv:** Exportado con su paleta de colores semántica en formato HEX.

Ambas fuentes han sido testeadas y están listas para ser conectadas en Tableau para dar inicio a la siguiente entrega.

Link del repositorio: <https://github.com/YuhiTTo/GRUPO5-DATAVISUALIZATION.git>

Referencias Bibliográficas

- EconoData Soluciones Perú. (2025). Ensayo: Inflación y coste de vida 2025. Recuperado de <https://econodatasolucionesperu.com/wp-content/uploads/2025/04/Ensayo-Inflacion-y-coste-de-vida-2025-N1.pdf>
- Instituto Nacional de Estadística e Informática (INEI). (2025). Pobreza monetaria afectó al 27,6% de la población del país en el año 2024. Gobierno del Perú. <https://www.gob.pe/institucion/inei/noticias/1164173-pobreza-monetaria-afecto-al-27-6-de-la-poblacion-del-pais-en-el-ano-2024>
- Oxfam en Perú. (2024). ENADES 2024: Encuesta Nacional de Percepción de Desigualdades. <https://peru.oxfam.org/ENADES-2024>
- Instituto Nacional de Estadística e Informática. (s. f.). *Microdatos: Sistema de Consulta de Microdatos*. Recuperado de <https://proyectos.inei.gob.pe/microdatos/>

Mini Ficha del Proyecto

Campo	Contenido
Título	Análisis de brechas socioeconómicas y evolución temporal de ingresos y gastos en los hogares peruanos durante el 2024
Pregunta analítica	¿Qué perfiles de hogares peruanos concentran las mayores brechas entre ingreso y gasto durante el 2024, y cómo se distribuyen estos perfiles (clústeres) según el dominio geográfico, el estrato y las características demográficas?
Usuario objetivo	Analistas de planeamiento y focalización del Ministerio de Desarrollo e Inclusión Social (MIDIS) que necesitan priorizar programas de asistencia basándose en los patrones de vulnerabilidad y brechas de ingreso-gasto identificadas mediante la segmentación de datos.

Fuente de datos	ENAH 2024 - Módulo 34: Sumaria (Variables Calculadas), INEI
Registros	33,691 viviendas
Periodo	Enero - Diciembre 2024
Herramientas	Python (limpieza, creación de métricas y modelo de clustering/PCA) + Tableau (dashboard exploratorio final)
Hipótesis 1	El algoritmo de clustering identificará un "perfil de alta vulnerabilidad" predominante en los estratos rurales, el cual se caracteriza por destinar una proporción crítica de su gasto total al rubro de alimentos, dejándolos sin margen frente a shocks inflacionarios.
Hipótesis 2	La distribución de los perfiles de hogares varía según la estacionalidad; existen meses específicos del año donde la brecha entre ingreso y gasto se acentúa, desplazando temporalmente a hogares de "perfiles estables" hacia "perfiles de riesgo".
Riesgos identificados	Presencia de outliers en variables de ingreso y gasto, y variables categóricas codificadas numéricamente que requieren traducción previa al análisis.
Producto final	Dashboard interactivo en Tableau que actúa como capa visual de un modelo de clustering (generado en Python), permitiendo explorar la distribución de perfiles de hogares según su brecha económica, temporalidad y geografía.