



UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

FACULTAD DE INGENIERÍA

PROGRAMA ACADÉMICO DE CIENCIAS DE LA COMPUTACIÓN

CURSO: 1ACC0211 – DATA VISUALIZATION

NRC: 18519

TRABAJO 6

INTEGRANTES:

Carbajal Robles, Daniel Ivan (U20221B751)

Manchay Paredes, Lucero Salome (U202216120)

Mayhua Hinostroza, José Antonio (U202218044)

Tabla de Contenido

1. Tema del proyecto.....	3
2. Pregunta analítica principal.....	3
3. Usuario objetivo.....	4
4. Fuente de datos propuesta.....	4
5. Hipótesis iniciales.....	4
6. Justificación del valor del proyecto.....	4
7. Diccionario de Datos (Variables Base y Métricas Derivadas).....	5
8. Bitácora de Transformación.....	12
9. Preprocesamiento para el Modelado.....	14
10. Opciones de Modelo Consideradas.....	14
11. Pruebas de Benchmarking Analítico.....	15
12. Definición del Modelo Seleccionado.....	16
13. Estructura analítica o relacional para Tableau.....	17
14. Métricas derivadas para visualización.....	17
15. Segmentación.....	17
16. Parámetros o lógica analítica.....	18
17. Fuentes finales o semidefinitivas para Tableau.....	18
18. Dashboard alpha y visualización exploratoria.....	18
18.1 Focalización del Problema Único Crítico.....	18
18.2 Focalización del Problema Único Crítico.....	19
18.3 Gráficos Seleccionados (4 Ejes).....	19
18.4 Gráficos Descartados.....	20
18.5 Redacción Analítica de Insights Exploratorios.....	21
19. Componente Avanzado: Reducción de Dimensionalidad (PCA y t-SNE).....	22
20. Matriz Final de Vistas del Dashboard: Justificación Longitudinal y Transversal.....	24
21. Ajuste Final, Accesibilidad y Diseño Visual.....	25
Referencias Bibliográficas.....	25
Mini Ficha del Proyecto.....	26

1. Tema del proyecto

Análisis de brechas socioeconómicas y evolución temporal de ingresos y gastos en los hogares peruanos durante el 2024

1.1 Definición del problema y del usuario objetivo

¿Qué problema se quiere analizar?

En el Perú, las cifras macroeconómicas suelen presentar una visión incompleta de la realidad al no reflejar las profundas disparidades que existen entre los hogares según su ubicación y el momento del año. Actualmente, el país enfrenta un entorno donde la inflación persistente y el incremento constante en el coste de vida consumen el poder adquisitivo de las familias de manera progresiva, agudizando su vulnerabilidad económica conforme avanzan los meses (EconoData Soluciones Perú, 2025). Esta presión financiera no se distribuye de forma equitativa: mientras regiones como Ica logran mantener niveles bajos de pobreza, departamentos como Cajamarca o Loreto enfrentan realidades críticas donde la vulnerabilidad alcanza a más del 40% de sus habitantes (INEI, 2025).

Esta desigualdad estructural se traduce en una percepción de precariedad generalizada, donde apenas el 14% de la población siente que sus ingresos son suficientes para cubrir sus necesidades y generar ahorro (Oxfam, 2024). Por lo tanto, el problema que este proyecto busca resolver es la falta de visibilidad articulada sobre cómo estas variables de ingreso y gasto fluctúan mes a mes, una información que es indispensable para identificar los periodos de mayor riesgo económico y diseñar respuestas que no solo sean geográficas, sino también estacionales.

¿Quién usará el dashboard?

- Analistas de planeamiento y focalización del Ministerio de Desarrollo e Inclusión Social (MIDIS).

¿Qué decisión podría apoyarse con el producto final?

- La priorización y asignación eficiente de programas de transferencias monetarias (bonos) y soporte alimentario, identificando los segmentos de hogares con mayor vulnerabilidad a partir del análisis de sus perfiles de brecha ingreso-gasto.

2. Pregunta analítica principal

¿Qué perfiles de hogares peruanos concentran las mayores brechas entre ingreso y gasto durante el 2024, y cómo se distribuyen estos perfiles (clústeres) según el dominio geográfico, el estrato y las características demográficas?

3. Usuario objetivo

Analistas de planeamiento y focalización del Ministerio de Desarrollo e Inclusión Social (MIDIS) que necesitan priorizar programas de asistencia basándose en los patrones de vulnerabilidad y brechas de ingreso-gasto identificadas mediante la segmentación de datos.

4. Fuente de datos propuesta

Nombre: Encuesta Nacional de Hogares (ENAHOG) 2024 - Módulo 34: Sumaria (Anual).

Institución: Instituto Nacional de Estadística e Informática (INEI).

Cantidad de datos: 33691 hogares

Cobertura: Nacional, 24 departamentos y la Provincia Constitucional del Callao, en ámbitos urbano y rural

Licencia y Permisos: Datos Abiertos Gubernamentales (Acceso público, gratuito y de libre uso para fines académicos e investigación).

Enlace oficial: [PERÚ Instituto Nacional de Estadística e Informática](#)

Pasos de obtención de datos: Microdatos INEI -> Consulta por Encuestas -> ENAHOG Metodología Actualizada -> Condiciones de Vida y Pobreza - ENAHOG -> Año 2024 -> Periodo: Anual -> "Módulo 34: Sumarias (Variables Calculadas)".

Dataset: "Sumaria-2024.csv"

5. Hipótesis iniciales

- Hipótesis 1: El algoritmo de clustering identificará un "perfil de alta vulnerabilidad" predominante en los estratos rurales, el cual se caracteriza por destinar una proporción crítica de su gasto total al rubro de alimentos, dejándolos sin margen frente a shocks inflacionarios.
- Hipótesis 2: La distribución de los perfiles de hogares varía según la estacionalidad; existen meses específicos del año donde la brecha entre ingreso y gasto se acentúa, desplazando temporalmente a hogares de "perfiles estables" hacia "perfiles de riesgo".

6. Justificación del valor del proyecto

El proyecto transforma una de las bases de datos gubernamentales más complejas en una herramienta visual interactiva que permite evidenciar cómo el lugar donde vive una familia determina drásticamente su estabilidad económica (Oxfam, 2024). El desarrollo de este dashboard cumple con el potencial requerido por el curso al permitir un análisis longitudinal (tendencias de gasto e impacto de la inflación mes a mes), segmentación (por niveles de pobreza y tamaño del hogar) y comparación geográfica (urbano vs. rural y dominios geográficos).

- **Adaptación a Tableau:** Elegimos Tableau por dos ventajas prácticas que nos ahorran tiempo y evitan errores. Primero, nos permite transformar los datos de ubicación en un mapa del Perú automáticamente, permitiéndonos visualizar la desigualdad regional sin tener que programar coordenadas desde cero. Segundo, Tableau nos permite configurar el "Factor de Expansión" (FACTOR07) como una regla matemática automática. Esto significa que la herramienta se encarga de ponderar los datos en tiempo real, asegurando que los gráficos no solo muestren una muestra, sino que reflejen con precisión la realidad de toda la población nacional.
- **Producto Analítico Subyacente:** Para responder a la pregunta de negocio sin caer en sesgos de causalidad, el dashboard servirá como la capa final de un modelo analítico exploratorio más profundo. Utilizaremos Python para el cálculo de la variable derivada "brecha ingreso-gasto" y aplicaremos técnicas de reducción de dimensionalidad y segmentación (PCA o k-means) sobre el módulo de sumarias. Esto nos permitirá descubrir "perfiles de hogares" basados en su estructura de consumo, los cuales serán posteriormente consumidos y visualizados en Tableau.
- **Riesgos iniciales de calidad y cobertura:** Antes de llevar los datos a Tableau, usaremos Python para solucionar dos problemas típicos de las encuestas del Estado. Primero, filtraremos los "outliers" (hogares que declaran ingresos extremadamente altos o irreales); si no los quitamos, el "ingreso promedio" en nuestros gráficos será engañoso. Segundo, traduciremos los códigos del INEI. Como la base de datos original usa números en lugar de texto (por ejemplo, usa el "15" en lugar de decir "Lima"), programaremos un script para convertir todos esos números a sus nombres reales, asegurando que Tableau pueda leer los mapas y las categorías sin confundirse.

Enlace del dataset:

<https://drive.google.com/file/d/1fNnNoEplQIQ9-jlwHUVkHHnpK8R47t-/view?usp=sharing>

El módulo Sumaria consolida a nivel de hogar los principales indicadores económicos del hogar, calculados con la metodología oficial del INEI, lo que garantiza comparabilidad con los reportes institucionales. Asimismo, estas variables cubren los tres ejes del análisis propuesto: la evolución mensual de los indicadores, la diferenciación por perfil socioeconómico y la comparación entre territorios.

7. Diccionario de Datos (Variables Base y Métricas Derivadas)

Variable	Tipo	Descripción	Eje Analítico	Justificación Técnica	Tratamiento en Limpieza
MES	String	Mes de ejecución de la encuesta	Temporal	Permite construir la serie	Se aseguró formato String de 2

				temporal mensual para analizar la estacionalidad de la brecha ingreso-gasto.	dígitos (padding con ceros a la izquierda).
UBIGEO	String	Código de ubicación geográfica	Geográfico	Permite georreferenciar los hogares en Tableau para construir mapas departamentales.	Se aseguró formato String de 6 dígitos (padding con ceros a la izquierda). Vital para mapas en Tableau.
DOMINIO	Categoría (String)	Dominio geográfico (Costa Norte, Sierra, Selva, Lima Metropolitana, etc.)	Segmentación geográfica	Permite comparar perfiles de hogares entre las grandes regiones naturales del país.	Se tradujo de Integer (1-8) a texto (Costa Norte, Sierra Centro, Lima Metropolitana, etc.).
ESTRATO	Categoría (String)	Estrato geográfico según tamaño de población	Segmentación geográfica	Diferencia el ámbito urbano del rural para identificar concentración de perfiles vulnerables.	Se tradujo de Integer (1-8) a texto descriptivo.
POBREZA	Categoría (String)	Condición de pobreza monetaria del hogar	Clasificación y filtro	Permite validar si los perfiles del clustering coinciden con la clasificación oficial del INEI.	Se tradujo de Integer (1-3) a texto (Pobre Extremo, Pobre No Extremo, No Pobre).
POBREZAV	Categoría (String)	Condición de pobreza y vulnerabilidad	Clasificación y filtro	Amplía la clasificación incluyendo	Se tradujo de Integer (1-4) a texto.

		ad del hogar		hogares vulnerables no pobres, enriqueciendo la segmentación.	
INGHOG2D	Float	Ingreso neto total del hogar	Métrica base	Ingreso real disponible del hogar, uno de los dos ejes para calcular la brecha ingreso-gasto.	Conservado como número. Se filtraron valores atípicos (outliers) mediante IQR con la mediana del grupo de pobreza correspondiente, sin eliminar filas.
GASHOG2D	Float	Gasto total bruto del hogar	Métrica base	Junto con INGHOG2D permite construir la brecha ingreso-gasto y determinar qué hogares logran ahorrar.	Conservado como número.
MIEPERHO	Integer	Total de miembros del hogar	Normalización	Permite calcular ingreso y gasto per cápita, haciendo comparables hogares de distinto tamaño.	Conservado como número.
GRU11HD	Float	Grupo 1: Alimentos - gasto monetario	Dimensión para PCA/clustering	Representa la proporción del gasto destinada a	Conservado como número.

				alimentación dentro de la estructura de consumo del hogar.	
GRU21HD	Float	Grupo 2: Vestido y calzado - gasto monetario	Dimensión para PCA/clustering	Captura el gasto en necesidades básicas secundarias para distinguir perfiles de consumo.	Conservado como número.
GRU31HD	Float	Grupo 3: Vivienda, combustible y electricidad- gasto monetario	Dimensión para PCA/clustering	Refleja el peso de los gastos fijos del hogar en servicios básicos.	Conservado como número.
GRU41HD	Float	Grupo 4: Muebles, enseres y mantenimiento - gasto monetario	Dimensión para PCA/clustering	Indica la capacidad del hogar para invertir más allá de las necesidades inmediatas.	Conservado como número.
GRU51HD	Float	Grupo 5: Salud y servicios médicos - gasto monetario	Dimensión para PCA/clustering	Permite detectar perfiles con acceso limitado o nulo a gasto en salud.	Conservado como número.
GRU61HD	Float	Grupo 6: Transportes y comunicaciones - gasto monetario	Dimensión para PCA/clustering	Refleja el nivel de movilidad e inserción económica del hogar.	Conservado como número.
GRU71HD	Float	Grupo 7: Esparcimiento, cultura y	Dimensión para PCA/clustering	Captura inversión en capital	Conservado como número.

		enseñanza - gasto monetario	ng	humano y calidad de vida del hogar.	
GRU81HD	Float	Grupo 8: Otros bienes y servicios - gasto monetario	Dimensión para PCA/clustering	Completa el vector de 8 variables numéricas requerido para el componente avanzado PCA/t-SNE.	Conservado como número.
FACTOR07	Float	Factor de expansión anual	Ponderación estadística	Garantiza que los cálculos representen a la población nacional y no solo a la muestra encuestada.	Conservado como número para su uso como ponderador en Tableau.
BRECHA_H OG	Float	Brecha absoluta del hogar	Métrica derivada	Diferencia directa entre INGHOG2D y GASHOG2D .	Calculada como INGHOG2D - GASHOG2D .
EN_DEFICI T	Integer	Indicador de déficit (0 o 1)	Clasificación	Flag analítico para identificar fácilmente hogares que gastan más de lo que ingresan.	Calculada como 1 si BRECHA_H OG < 0, sino 0.
ING_PERC APITA	Float	Ingreso por miembro	Normalizaci ón	Permite comparar hogares de distinto tamaño.	Calculada como INGHOG2D / MIEPERHO.
GAS_PERC APITA	Float	Gasto por miembro	Normalizaci ón	Permite comparar hogares de	Calculada como GASHOG2D

				distinto tamaño.	/ MIEPERHO.
BRECHA_P ERCAPITA	Float	Brecha por miembro	Normalización	Métrica comparable de capacidad de ahorro/déficit entre hogares.	Calculada como BRECHA_HOG / MIEPERHO.
MES_NUM	Integer	Mes numérico	Tiempo	MES como string puede ordenarse lexicográficamente en lugar de cronológicamente en Tableau. La versión entera garantiza orden correcto en ejes temporales.	Conversión de MES a numérico.
DEPARTAMENTO	String	Nombre del departamento	Comparación geográfica	UBIGEO de 6 dígitos no tiene semántica legible. Se extrae el código de departamento (primeros 2 dígitos) y se mapea al nombre oficial INEI para comparaciones y mapas	Derivada de los 2 primeros dígitos del UBIGEO.

				departamentales.	
LOG_INGHOG2D / LOG_GASHOG2D / LOG_BRECHA_PERCAP	Float	Logaritmo de Ingresos, Gastos y Brecha	Distribución	Ingresos y gastos tienen distribución fuertemente sesgada a la derecha. La transformación logarítmica permite leer histogramas y box plots sin que la cola aplaste la varianza central.	Aplicación de logaritmo log1p.
GRU{i}1HD_PCT	Float	% de participación de los 8 rubros de gasto	Relación / composición	Los montos brutos de cada rubro son incomparables entre hogares de distinto nivel de ingreso. La proporción sobre la canasta monetaria total normaliza la comparación.	Calculada dividiendo el gasto de cada rubro (ej. 'GRU11HD') entre la suma estricta de los 8 rubros ('GRU11HD' a 'GRU81HD').
TASA_AHORRO	Float	Margen de brecha relativa	Métrica derivada (Clustering)	Permite medir qué porcentaje de su ingreso total logra ahorrar el hogar,	Calculada como '(INGHOG2D - GASHOG2D) / INGHOG2D'

				normalizando la brecha absoluta.	. Si el ingreso es 0, la tasa es 0.
ID_SEGMENTO	Integer	Llave foránea del perfil financiero	Segmentación (Clustering)	Identifica si el hogar es Ahorrador Sólido, Equilibrio, Déficit Leve o Déficit Crítico.	Asignada mediante condicionales sobre la `TASA_AHORRO`.
PCA_VALIDO	Integer	Flag de validez para el componente PCA (0 o 1)	Clustering / PCA	Excluye el ajuste del PCA a los 18 hogares sin ningún gasto registrado en los 8 rubros, evitando que colapsen artificialmente en un mismo punto del biplot	Calculado como 1 si la suma de los 8 `GRU{i} HD_PCT` es mayor a 0, sino 0.

8. Bitácora de Transformación

8.1 Detección de Codificación: Se leyó el dataset original (“Sumaria-2024.csv”) usando codificación “latin1” para evitar la corrupción de caracteres especiales en las cabeceras.

8.2 Reducción de Dimensionalidad: Se eliminaron las columnas innecesarias del módulo original, reduciendo el dataset estrictamente a las 18 variables arriba listadas.

8.3 Conversión de Identificadores (UBIGEO y MES): La columna “UBIGEO” se convirtió a String forzando un padding con ceros a la izquierda mediante el uso de la función “zfill(6)”. Esto soluciona que Tableau no lea los UBIGEos que inician con “0” (como Amazonas = 010101) como números enteros. Igual tratamiento se aplicó para “MES” con “zfill(2)”.

8.4 Traducción de variables (DOMINIO, ESTRATO, POBREZA y POBREZAV): Se construyeron diccionarios en memoria y se utilizó la función “.map()” de Pandas para traducir los códigos numéricos a texto descriptivo.

8.5 Manejo de Outliers: Se detectaron valores atípicos en las variables de ingresos y gastos utilizando el método del Rango Inter cuartílico (IQR). A diferencia de entregas previas, no se eliminaron filas. En su lugar, se imputaron los valores extremos con la mediana del grupo de pobreza al que pertenece el hogar. Esto permite conservar los 33,691 registros originales sin distorsionar la realidad de la brecha económica del país. Este tratamiento, aunque metodológicamente correcto, no es neutral: se imputaron 2,037 valores de INGHOG2D y 1,589 valores de GASHOG2D, lo que mueve 2,360 hogares (7.0% de la muestra) de segmento financiero (ID_SEGMENTO) y eleva la incidencia ponderada de Déficit Crítico de 22.46% en los datos crudos de la ENAHO a 24.54% en la base transformada. Se documenta explícitamente para que la cifra de 24.5% no se presente como un dato crudo de la encuesta, sino como resultado de la base ya tratada. Además, se crearon versiones logarítmicas de estas variables para su posterior uso en modelos.

8.6 Exportación y corrección de Encoding (ESTRATO): Se exportó el dataset limpio bajo el nombre “Sumaria-2024_limpio.csv” forzando el formato de codificación “utf-8-sig” (UTF-8 con BOM). Esta corrección del encoding solucionó el problema en la variable ESTRATO, donde caracteres como “Área” y “más” se mostraban corruptos en Tableau o Excel. Además, se forzó el uso de comillas dobles para variables tipo texto.

8.7 Modelado de Datos: Se estructuró la data limpia en un Esquema Estrella creando una Tabla de Hechos y Dimensiones (Geografía, Tiempo, Pobreza) tras corroborar mediante pruebas de estrés (Benchmarking) un ahorro de RAM del 33% frente a la Tabla Plana. En esta fase de importación/exportación se re-aplicó el “.astype(str).str.zfill(6)” al “UBIGEO” para evitar que la lectura de Pandas lo interpretará como entero por defecto y truncara los ceros a la izquierda geográficos.

8.8 Cálculos Analíticos y Segmentación: Se añadió la métrica derivada “TASA_AHORRO” a la tabla de hechos. Con esta métrica, se crearon 4 clústeres financieros plasmados en la nueva tabla “dim_segmento”. Además, se recalculó la matemática de las participaciones porcentuales de gasto (“_PCT”) para que el denominador sea la suma estricta de la canasta y no el gasto bruto (“GASHOG2D”), garantizando que la suma por hogar sea exactamente “1.0” (100%). Se validó que no existan llaves foráneas nulas y que los tipos de datos sean compatibles nativamente con Tableau.

8.9 Diseño Analítico de Visualización Exploratoria: Se estableció el enfoque de “Problema Único Crítico” (Laser-Focused en la trampa del Déficit Crítico alimentario del Clúster 4). Se generó la matriz de selección oficial de 4 gráficos (Composición en Mapa de Calor / Resaltar Tabla, Ranking Departamental en Barras Horizontales,

Tendencia Estacional en Líneas y Distribución en Boxplot con truncamiento visual) y se fundamentó empíricamente el descarte técnico de 2 gráficos preliminares (Scatter crudo por Overplotting y Treemap/Burbujas por asimetría de magnitudes). Asimismo, se enriqueció la dimensión temporal con los nombres literales de los meses en español.

9. Preprocesamiento para el Modelado

Para esta entrega, el objetivo fue preparar la arquitectura de datos que será consumida directamente por Tableau. Se partió del archivo Sumaria-2024_limpio.csv (33,691 registros y 26 variables, incluyendo métricas derivadas).

Pasos ejecutados de forma reproducible:

9.1. Generación de Claves Primarias: Dado que en la reducción de dimensionalidad se eliminaron las llaves originales del INEI (CONGLOME, VIVIENDA, HOGAR), se generó una clave primaria secuencial subrogada ID_HOGAR (del 1 al 33,691) para garantizar que cada registro sea único en la tabla principal y optimizar la velocidad computacional en Tableau.

9.2. Generación de Claves para Dimensiones: Se crearon claves foráneas como “ID_POBREZA” (secuencial) e “ID_GEOGRAFIA” (secuencial) cruzando combinaciones únicas de atributos categóricos, garantizando integridad referencial.

9.3. Formateo Estructural de Identificadores: Las herramientas como Tableau dependen de tipos de datos estrictos. Se forzó el tipado String para el “UBIGEO” aplicando la función “zfill(6)” durante la carga. Esto soluciona un error crítico de ingesta dónde códigos geográficos como Amazonas (“010101”) perdían su cero a la izquierda.

9.4. Validación de Integridad: Se validó de forma automatizada (mediante asserts en Python) que hacer un “inner join” entre la Tabla de Hechos y las Tablas de Dimensión diera como resultado exactamente las mismas 33,691 filas iniciales, asegurando cero pérdida de datos.

10. Opciones de Modelo Consideradas

Como las herramientas de visualización de datos como Tableau requieren estructuras altamente eficientes para procesar millones de registros, se compararon dos modelos clásicos de Data Warehousing:

Opción 1: Modelo de Tabla Plana (Flat Table) - Modelo Base

Es una única tabla desnormalizada ("sábana de datos") donde toda la información se concentra en cada registro.

- **Funcionamiento:** Similar a un archivo Excel tradicional. Si hay 10,000 hogares en “Lima Metropolitana”, el texto se repite 10,000 veces.
- **Ventaja:** Fácil lectura humana directa sin necesidad de realizar cruces de tablas.

- **Desventaja (Por qué se descartó):** Altísima redundancia. Demostramos empíricamente que proyectar datos históricos en este formato hace que el archivo se vuelva insosteniblemente pesado en memoria.

Opción 2: Esquema Estrella (Star Schema) - Modelo Propuesto

Un modelo normalizado donde el dataset se divide en una tabla central rodeada de dimensiones lógicas (diccionarios):

- **Tabla de Hechos (fact_hogares):** Guarda estrictamente números puros (Gastos, Ingresos, Brechas, IDs) y las llaves foráneas. Cero texto descriptivo.
- **Las Dimensiones:** Son diccionarios para Geografía (dim_geografia), Tiempo (dim_tiempo) y Pobreza (dim_pobreza).
- **Ventaja:** Elimina la redundancia ahorrando memoria masivamente (33%). Además, permite que Tableau renderice visualizaciones a máxima velocidad porque solo requiere un salto directo (1 Join) desde los Hechos a cualquier Dimensión.

Opción 3: Esquema Copo de Nieve (Snowflake Schema)

Es una variación de la Estrella llevada a una normalización extrema (3NF), donde las ramas se rompen en pedazos más pequeños:

- **Funcionamiento:** La dimensión geográfica se disgrega. “dim_geografia_snow” elimina el texto del departamento y lo vincula a una nueva tabla aislada “dim_departamento” mediante un “ID_DEP”.
- **Desventaja (Por qué se descartó):** Aunque logra una compresión fraccionalmente mejor, obliga al motor de Tableau a realizar múltiples saltos en cascada (Joins encadenados: Hechos -> Geografía -> Departamento). Este costo topológico ralentiza los cruces sin justificar el minúsculo ahorro de RAM.

11. Pruebas de Benchmarking Analítico

Para no depender de preferencias técnicas, se ejecutó un script en Python que calculó matemáticamente el peso en Memoria RAM (Sparsity) y el Costo Topológico de cada arquitectura sobre nuestros 33,691 registros:

Métrica Evaluada (Evidencia)	Alternativa Base (Tabla Plana)	Opción 1 (Esquema Estrella)	Opción 2 (Copo de Nieve)	Veredicto Empírico
Memoria RAM (MB)	12.15 MB	8.15 MB (-32.88%)	8.14 MB (-32.98%)	Ambos esquemas relacionales reducen la redundancia categórica en casi un 33%. El Copo de Nieve ahorra marginalmente (0.01

				MB).
Proyección a 5 Años (MB)	60.73 MB	40.03 MB (-34.08%)	40.01 MB (-34.11%)	Al simular 5 años históricos, la brecha absoluta de ahorro sube a más de 20 MB, ya que las dimensiones estrella permanecen estáticas.
Costo Topológico (Saltos)	Bajo (0 Joins)	Moderado (1 Join directo)	Alto (2 Joins en cascada)	El Copo de Nieve exige un Join adicional (Geografía -> Departamento), degradando la velocidad de lectura en Tableau.

12. Definición del Modelo Seleccionado

Decisión: El modelo seleccionado para alimentar el Dashboard de la Entrega 4 es la Opción 1: Esquema Estrella (Star Schema).

Justificación Basada en Evidencia:

A diferencia del enfoque tradicional, hemos basado la decisión en mediciones exactas extraídas de Python (benchmarking_resultados.csv):

- **Prueba de Escalabilidad:** La Tabla Plana se descartó porque demostramos empíricamente su fragilidad histórica. Al simular la inyección de 5 encuestas anuales (2020-2024), la redundancia de texto (ej. repetir "Lima Metropolitana" miles de veces) provoca que la Tabla Plana colapse consumiendo 60.73 MB de memoria RAM. Por el contrario, el Esquema Estrella mantiene estáticas sus dimensiones geográficas y de pobreza, limitando el consumo a 40.03 MB (un ahorro proyectado del 34.08%).
- **Costo Topológico:** El Copo de Nieve logró comprimir la memoria en proporciones casi idénticas a la Estrella (solo ganamos 0.02 MB extra). Sin embargo, nos penaliza con un salto de Join adicional en cascada. Ejemplo práctico: Si en Tableau el usuario quiere filtrar los gastos por "Amazonas", en el Esquema Estrella el sistema viaja directo de la Tabla de Hechos a la de Geografía (1 salto). En el Copo de Nieve, tiene que viajar de los Hechos a la Geografía, y de ahí al Departamento (2 saltos). Esta cadena de cruces haría que los mapas departamentales en Tableau se rendericen mucho más lento.

Por lo tanto, la evidencia indica que el Esquema Estrella es el punto de equilibrio óptimo entre máxima compresión de memoria para datos históricos (ahorro del 34.08% a 5 años) y velocidad de consulta directa (1 Join).

13. Estructura analítica o relacional para Tableau

Se mantiene la arquitectura en Esquema Estrella centralizada. Para cumplir con las mejores prácticas y no duplicar métricas sin control en la tabla de hechos, se diseñó e integró una nueva dimensión analítica llamada dim_segmento.

- **Validación:** Se ejecutaron pruebas de integridad referencial asegurando que la conexión entre fact_hogares y sus dimensiones (incluyendo la nueva llave foránea ID_SEGMENTO) presenta ausencia absoluta de valores Nulos y tipado Entero. Esto asegura una conexión nativa y fluida en Tableau sin reprocesamiento manual.

14. Métricas derivadas para visualización

Para responder de forma precisa a nuestra pregunta analítica sobre brechas económicas, se generó una métrica derivada transversal:

Tasa de Ahorro (Margen de Brecha Relativa):

- **Cálculo:** $(INGHOG2D - GASHOG2D) / INGHOG2D$.
- **Impacto en la interpretación:** A diferencia de la brecha absoluta, esta métrica relativa nos permite comparar equitativamente la capacidad financiera de hogares ricos y pobres. Un déficit de 500 soles no significa lo mismo para quien gana 1,000 que para quien gana 10,000.
- **Corrección Analítica:** Se recalcularon las participaciones proporcionales de gasto (_PCT) tomando como base la suma estricta de la canasta de 8 rubros, en lugar del Gasto Bruto (el cual incluía componentes no monetarios). Esto garantiza que, al apilar barras al 100% en Tableau, las sumas sean matemáticamente exactas.

15. Segmentación

Con base en la TASA_AHORRO, se creó un clúster financiero para agrupar a los hogares en 4 perfiles de vulnerabilidad, independientemente de la clasificación oficial de pobreza. Casi 1 de cada 4 hogares peruanos (23.8%) se ubica en el déficit más extremo:

- **Ahorrador Sólido (ID_SEGMENTO = 1):** Tasa $\geq 15\%$. Alta holgura económica mensual. (Paleta: Verde)
- **Equilibrio / Supervivencia (ID_SEGMENTO = 2):** $0\% \leq \text{Tasa} < 15\%$. Nula o escasa capacidad de ahorro; vulnerables a shocks. (Paleta: Naranja)
- **Déficit Leve (ID_SEGMENTO = 3):** $-15\% \leq \text{Tasa} < 0\%$. Gastan por encima de sus ingresos, con deuda manejable. (Paleta: Rojo)
- **Déficit Crítico (ID_SEGMENTO = 4):** Tasa $< -15\%$. Hogares en estrés financiero severo. (Paleta: Marrón)

16. Parámetros o lógica analítica

Para el futuro Dashboard, se diseñó la lógica analítica de un "Simulador de Inflación Alimentaria".

- **Diseño del Parámetro:** [Inflación Alimentos] (Rango: 0 a 0.50).
- **Cálculo Afectado:** $\text{Gasto_Simulado} = \text{GASHOG2D} + (\text{GRU11HD} * [\text{Inflación Alimentos}])$.
- **Interpretación:** Este parámetro de interacción permitirá al usuario simular un shock inflacionario en tiempo real, observando cuántas familias caerían del segmento "Equilibrio" al "Déficit Crítico" si el costo de los alimentos sube, agregando gran valor al análisis exploratorio.

17. Fuentes finales o semidefinitivas para Tableau

El procesamiento concluyó con la exportación del modelo optimizado a la carpeta Data/modelo/esquema_estrella/.

- **fact_hogares.csv:** Actualizado con las nuevas métricas (Tasa de Ahorro y ID_SEGMENTO).
- **dim_segmento.csv:** Exportado con su paleta de colores semántica en formato HEX.

Ambas fuentes han sido testeadas y están listas para ser conectadas en Tableau para dar inicio a la siguiente entrega.

18. Dashboard alpha y visualización exploratoria

18.1 Focalización del Problema Único Crítico

Acatando las mejores prácticas de diseño ejecutivo y las directrices metodológicas del curso enfocarse en un solo problema específicamente, el prototipo funcional navegable “Dashboard Alpha” centra todo su argumento visual en el hallazgo más estructural y crítico descubierto en las fases analíticas previas:

“Focalización MIDIS 2024: ¿Qué departamentos concentran la mayor incidencia de hogares en Déficit Crítico operativo y cuál es el impacto en su seguridad alimentaria?”

El Problema Crítico de Negocio: El 23.8% de los hogares peruanos (casi 1 de cada 4) opera bajo un régimen de Déficit Crítico financiero ($\text{ID_SEGMENTO} = 4$, Tasa de Ahorro $< -15\%$). El análisis exploratorio evidencia que estas familias no sufren de un endeudamiento suntuuario o secundario, sino de un déficit de subsistencia primaria: destinan en promedio el “48.0%” de su gasto monetario exclusivamente a alimentarse (GRU11HD_PCT), dejándolos con un margen de holgura nulo ante choques inflacionarios en la canasta básica.

18.2 Focalización del Problema Único Crítico

La selección visual del Workbook preliminar en Tableau responde estrictamente a la matriz oficial de decisiones del curso (Elección de gráficos por zona), garantizando que cada vista responda a una pregunta analítica accionable y no a preferencias estéticas.

18.3 Gráficos Seleccionados (4 Ejes)

Eje Analítico	Gráfico Oficial Seleccionado	Variables Mapeadas en Tableau	Justificación Técnica Breve (Matriz de Elección del Curso)	Ubicación Operativa
Relación / Composición	Mapa de Calor (Resaltar Tabla)	- Columnas: ID_SEGMENT O (Clúster 1 al 4) - Filas: Nombres de medida (GRU11HD_PC T a GRU81HD_PC T) - Texto y Color: Valores de medida	Presenta una matriz visual limpia con porcentajes exactos impresos en cada celda sin solapamiento ni adivinanzas. Mediante leyendas separadas, evidencia con intensidad semántica roja que el rubro Alimentos absorbe el 48.0% del Clúster 4.	Vista Principal Dominante (Lienzo Central)
Comparación / Ranking	Gráfico de barras horizontales ordenadas	- Eje Y: DEPARTAMENTO - Eje X: % de Hogares en ID_SEGMENT O = 4 - Orden: Descendente	Reemplaza al mapa tradicional para garantizar una lectura limpia y comparativa de magnitudes territoriales en espacios compactos, evitando que departamentos geográficamente	Soporte A (Recuadro Inferior Izquierdo)

			e pequeños (ej. Ica, Callao, Tumbes) pierdan visibilidad.	
Tendencia Temporal	Gráfico de líneas continuas	- Eje X: MES (Enero a Diciembre) - Eje Y: % de Déficit Crítico (AGR)	Conecta observaciones agregadas longitudinales, revelando puntos de inflexión estacionales donde la incidencia de quiebra familiar alcanza su pico crítico en el primer trimestre (abril con 27.6%) antes de moderarse hacia diciembre (22.0%).	Soporte B (Recuadro Inferior Derecho)
Distribución	Diagrama de caja y bigotes (Boxplot)	- Eje X: DOMINIO (Regiones naturales) - Eje Y: TASA_AHORRO (eje fijo -15% a +15%) - Detalle: ID_HOGAR	Evalúa la mediana central, dispersión intercuartílica (IQR) y valores atípicos territoriales de la capacidad financiera familiar mediante truncamiento visual de escala para maximizar la legibilidad.	Dashboard Alpha (Integrado en Tooltip visual sobre Soporte A / accesible en navegación de pestañas)

18.4 Gráficos Descartados

Para demostrar rigor metodológico, se evitó documentar descartes genéricos obvios prohibidos universalmente en cátedra (como Pie Explorado o Eje Dual). En su lugar, se documenta el descarte de gráficos del sílabo oficial que teóricamente parecerían candidatos viables, pero que fallan por la topología y volumen del dataset ENAHO (33,691 observaciones):

Descarte Técnico 1: Diagrama de dispersión único (Scatter Plot crudo de Ingreso vs. Gasto)

- **Pertenencia al sílabo:** Enseñados oficialmente para resolver "Relación entre métricas (Scatter con color)".
- **Justificación de descarte contextual:** Al proyectar simultáneamente los 33,691 puntos individuales del módulo Sumaria, se produce un colapso visual severo denominado Overplotting (solapamiento masivo): los puntos se amontonan en los deciles medios y bajos formando una mancha oscura ilegible que oculta la verdadera densidad de vulnerabilidad. Para garantizar una toma de decisiones de políticas públicas en milisegundos por parte del MIDIS, es fisiológicamente superior sintetizar la relación en los 4 Clústeres Financieros (`dim_segmento``).

Descarte Técnico 2: Diagrama de árbol (Treemap) o Gráfico de burbujas apiladas

- **Pertenencia al sílabo:** Enseñados como alternativas visuales para mostrar la composición de partes de un todo.
- **Justificación de descarte contextual:** Los 8 rubros de gasto de la ENAHO presentan una disparidad de magnitud extrema (Alimentos representa ~48%, mientras que Salud o Enseñanza apenas ~2%). En un Treemap o Burbujas, los recuadros o círculos de los rubros pequeños colapsan visualmente y sus etiquetas numéricas se truncan en errores legibles ("####"). Fisiológicamente, el ojo humano evalúa proporciones con mayor precisión al comparar longitudes alineadas sobre un eje base (Stacked Bar) que áreas bidimensionales flotantes.

18.5 Redacción Analítica de Insights Exploratorios

Para cumplir con el requisito de la rúbrica oficial (documento corto con 3 a 5 insights exploratorios en lenguaje analítico), se presentan 3 grandes insights institucionales. Acatando la estructura operativa de la cátedra, el Insight 1 es el que irá incrustado en el recuadro lateral único del Dashboard Alpha, mientras que los Insights 2 y 3 complementan la exploración del Workbook preliminar.

Insight 1: Asfixia Alimentaria y Trampa Rural

1. QUE: El 23.8% de los hogares peruanos (~2.4M familias) opera en Déficit Crítico (`ID_SEGMENTO = 4`). Presentan asfixia calórica severa: destinan el 48.0% de su gasto exclusivamente a comer, operando con una brecha media de -S/ 286 mensuales per cápita.

2. POR QUÉ: La quiebra familiar se concentra en el sur y norte rural, liderada por Puno (37.3%), Huancavelica (31.2%) y Loreto (30.6%) por desacople agropecuario. Estacionalmente, la tensión alcanza su pico máximo en abril (27.6% de déficit).

3. ACCIÓN: Priorizar el Programa de Complementación Alimentaria (PCA) en las provincias críticas, otorgando subsidios e insumos calóricos a comedores populares y ollas comunes, reforzando la asistencia durante el primer cuatrimestre del año.

Insight 2: El Gasto en Salud como Déficit Oculto

1. QUE: Contra Intuitivamente, los hogares en Déficit Crítico gastan más en salud en monto absoluto que los Ahorradores Sólidos (S/ 1,417 vs S/ 1,048 anuales), absorbiendo el 7.1% de su canasta frente al 5.6% del estrato superavitario.

2. POR QUÉ: Evidencia que el déficit no obedece a consumos superfluos, sino a emergencias médicas inelásticas no cubiertas que obligan al desahorro y gasto de bolsillo (out-of-pocket).

3. ACCIÓN: Ampliar la cobertura de medicamentos e intervenciones del Seguro Integral de Salud (SIS) para los hogares del Clúster 4, liberando presupuesto familiar para la nutrición básica.

Insight 3: La Paradoja del "No Pobre" en Déficit

1. QUE: El 81.7% de los hogares en Déficit Crítico es clasificado como "No Pobre" por el INEI (6,545 de 8,009 familias encuestadas en quiebra no aparecen en los padrones oficiales de pobreza).

2. POR QUÉ: Existe una fractura entre la medición monetaria de pobreza (evaluada sólo por ingresos brutos) y la vulnerabilidad financiera operativa real (evaluada por el balance neto y capacidad de ahorro).

3. ACCIÓN: Incorporar la "TASA_AHORRO" y el balance operativo como criterios de elegibilidad en el Sistema de Focalización de Hogares (SISFOH), protegiendo a las familias vulnerables excluidas por el estándar tradicional.

19. Componente Avanzado: Reducción de Dimensionalidad (PCA y t-SNE)

Esta sección documenta la incorporación de un componente analítico avanzado de reducción de dimensionalidad sobre la composición porcentual del gasto.

Como extensión analítica sobre las 8 variables de composición porcentual del gasto (GRU_i HD_PCT), se implementó un componente de reducción de dimensionalidad para evaluar si el perfil de consumo de un hogar discrimina geométricamente su segmento financiero.

Análisis de Componentes Principales (PCA): El primer componente principal (PC1) explica 22.85% de la varianza y el segundo (PC2) 16.46% (39.31% acumulado). Los loadings de PC1 muestran que Alimentos y bebidas (+0.665) se opone a Vestido y calzado (-0.352) y Transporte y comunicaciones (-0.388), sugiriendo un eje de "necesidad básica vs. consumo diversificado".

Validez de datos (PCA_VALIDO): Se identificaron 18 hogares sin ningún gasto registrado en los 8 rubros (composición porcentual en cero), que fueron excluidos del ajuste del PCA mediante un flag PCA_VALIDO, evitando que colapsaran artificialmente en un mismo punto del biplot.

Comparación con t-SNE: Se evaluó t-SNE como alternativa no lineal de reducción de dimensionalidad

Criterio	PCA (modelo elegido)	t-SNE (alternativa evaluada)
Naturaleza	Lineal, determinística	No lineal, estocástica (depende de la semilla aleatoria)
Interpretabilidad	Loadings exactos y asignables por variable	Caja negra; sin coeficientes interpretables
Complejidad computacional	$O(N)$ - se ajusta sobre los 33,673 hogares	$O(N \log N)$ con Barnes–Hut (no $O(N^2)$, como se documentó preliminarmente)
Tiempo de cómputo	48 milisegundos sobre el dataset completo	Requiere muestra estratificada de 3,000 hogares para mantener interactividad
Reproducibilidad	100% idéntico en cada corrida	Sensible a la semilla aleatoria (se validó con 2 semillas distintas)
Veredicto	Elegido: mismo poder discriminativo (Silhouette ≈ 0) con total transparencia interpretativa	Descartado como modelo final por falta de loadings, pese a ser computacionalmente viable

Prueba de robustez (Silhouette Score): Para confirmar que el hallazgo no depende de la imputación de outliers, se recalculó el Silhouette Score usando segmentos derivados de los datos crudos sin imputar. El resultado (-0.0267) es consistente en orden de magnitud y signo con el obtenido sobre los datos transformados (-0.0372), con una diferencia de apenas 0.0105. Esto confirma que el hallazgo central es robusto: la composición porcentual del gasto no discrimina geométricamente el segmento financiero del hogar, independientemente de cómo se traten los valores atípicos.

20. Matriz Final de Vistas del Dashboard: Justificación Longitudinal y Transversal

Eje Analítico	Gráfico Oficial del Dashboard	Tipo de Vista	Justificación
Tendencia Temporal (Evolución / Estacional)	Soporte B: Gráfico de Líneas (Line Chart)	VISTA LONGITUDINAL	Evalúa la trayectoria de la brecha a lo largo del tiempo (Enero a Diciembre 2024), descubriendo que en Abril (27.6%) se alcanza el pico de asfixia financiera por el shock del calendario escolar y agrícola.
Relación / Composición (Estructura Interna)	Vista Dominante: Tabla de Texto Resaltada (Highlight Table)	VISTA TRANSVERSAL (Estructural)	Evalúa transversalmente cómo se reparten los 8 rubros de gasto en un momento dado, demostrando la inelasticidad de la canasta básica (48.0% en Alimentos en el Clúster 4).
Comparación / Ranking (Territorial)	Soporte A: Barras Horizontales Ordenadas (Sorted Bar Chart)	VISTA TRANSVERSAL (Geográfica)	Compara transversalmente a los 24 departamentos de manera simultánea, revelando la severa fractura rural en la Sierra y Selva (Puno 37.3%, Huancavelica 31.2%).
Distribución / Clustering (Reducción Dimensional)	Hoja PCA: Diagrama de Dispersión (Scatter Plot PC1 vs PC2)	VISTA TRANSVERSAL (Multivariada)	Reemplaza y supera al viejo Boxplot de la Entrega 5: evalúa la distribución topológica de los 33,691 hogares, demostrando con su silueta cercana a cero (-0.0214) que el déficit es homogéneo en

			hábitos de compra.
Coherencia Monetaria (Preguntas Q&A)	Soporte Q&A (Hoja 9): Scatter Plot Agregado	VISTA TRANSVERSAL (Monetaria)	Muestra las 4 marcas agregadas (Ingreso vs. Gasto absoluto) para defender en la ronda de preguntas que la brecha per cápita de -S/ 312 es una pérdida monetaria real.

21. Ajuste Final, Accesibilidad y Diseño Visual

Acatando el contenido obligatorio de la Entrega 6, la versión final del Dashboard en Tableau integra mejoras críticas en usabilidad, accesibilidad y jerarquía visual:

- **Blindaje Directivo en el Banner Superior:** Para prevenir errores de interpretación macroeconómica, se configuró una barra de filtros y subtítulo declarativo: Periodo: 2024 | Foco Analítico de KPIs: Hogares en Déficit Crítico (ID_SEGMENTO = 4, 24.5% Ponderado Nacional). Esto transparenta desde el segundo cero que las 4 tarjetas cuantifican exclusivamente a la población en quiebra y no a todo el país.
- **Tarjetas KPI con Benchmarking Comparativo:** Cada uno de los 4 KPIs superiores incorpora en su subtítulo un comparador o punto de referencia en vivo (vs. 75.5% Resto del País, vs. +S/ 112 Superávit Nacional, vs. Umbral < -15%, y vs. 46.6% Ahorrador Sólido). Esto cumple con la regla de oro de visualización directiva: un KPI debe evaluarse frente a un estándar para ser accionable.
- **Accesibilidad y Paleta Semántica:** Se emplean colores funcionalmente asignados (Rojo para Déficit Crítico, Verde para Ahorrador, Naranja para Equilibrio) con suficiente contraste de luminancia para asegurar accesibilidad y rápida decodificación cognitiva.
- **Anti-Overplotting:** Se reemplazaron gráficos dispersos masivos por agregaciones claras (Highlight Table y Sorted Bars), evitando saturación visual y facilitando la decisión pública en segundos.

Link del repositorio: <https://github.com/YuhiTTo/GRUPO5-DATAVISUALIZATION.git>

Referencias Bibliográficas

- EconoData Soluciones Perú. (2025). Ensayo: Inflación y coste de vida 2025. Recuperado de <https://econodatasolucionesperu.com/wp-content/uploads/2025/04/Ensayo-Inflacion-y-coste-de-vida-2025-N1.pdf>

- Instituto Nacional de Estadística e Informática (INEI). (2025). Pobreza monetaria afectó al 27,6% de la población del país en el año 2024. Gobierno del Perú. <https://www.gob.pe/institucion/inei/noticias/1164173-pobreza-monetaria-afecto-al-27-6-de-la-poblacion-del-pais-en-el-ano-2024>
- Oxfam en Perú. (2024). ENADES 2024: Encuesta Nacional de Percepción de Desigualdades. <https://peru.oxfam.org/ENADES-2024>
- Instituto Nacional de Estadística e Informática. (s. f.). *Microdatos: Sistema de Consulta de Microdatos*. Recuperado de <https://proyectos.inei.gob.pe/microdatos/>

Mini Ficha del Proyecto

Campo	Contenido
Título	Análisis de brechas socioeconómicas y evolución temporal de ingresos y gastos en los hogares peruanos durante el 2024
Pregunta analítica	¿Qué perfiles de hogares peruanos concentran las mayores brechas entre ingreso y gasto durante el 2024, y cómo se distribuyen estos perfiles (clústeres) según el dominio geográfico, el estrato y las características demográficas?
Usuario objetivo	Analistas de planeamiento y focalización del Ministerio de Desarrollo e Inclusión Social (MIDIS) que necesitan priorizar programas de asistencia basándose en los patrones de vulnerabilidad y brechas de ingreso-gasto identificadas mediante la segmentación de datos.
Fuente de datos	ENAHO 2024 - Módulo 34: Sumaria (Variables Calculadas), INEI
Registros	33,691 hogares
Periodo	Enero - Diciembre 2024
Herramientas	Python (limpieza, creación de métricas y modelo de clustering/PCA) + Tableau (dashboard exploratorio final)
Hipótesis 1	El algoritmo de clustering identificará un "perfil de alta vulnerabilidad" predominante en los estratos rurales, el cual se caracteriza por destinar

	una proporción crítica de su gasto total al rubro de alimentos, dejándolos sin margen frente a shocks inflacionarios.
Hipótesis 2	La distribución de los perfiles de hogares varía según la estacionalidad; existen meses específicos del año donde la brecha entre ingreso y gasto se acentúa, desplazando temporalmente a hogares de "perfiles estables" hacia "perfiles de riesgo".
Riesgos identificados	Presencia de outliers en variables de ingreso y gasto, y variables categóricas codificadas numéricamente que requieren traducción previa al análisis.
Producto final	Dashboard interactivo en Tableau que actúa como capa visual de un modelo de clustering (generado en Python), permitiendo explorar la distribución de perfiles de hogares según su brecha económica, temporalidad y geografía.